

Atividade 03 - Avaliação final

- Responda todas as questões abaixo.
- A resposta de cada questão deve estar abaixo da questão, que nem numa prova normal.
- Preste atenção, nem todas usam o mesmo banco de dados.
- No final deste documento, deixei alguns links que podem ajudar vocês.

1) Faça a avaliação geral dos data set e realize uma breve análise dos dados.

Dados disponíveis neste [link](#). Faça download do arquivo `NFL Play by Play 2009-2016 (v3).csv` e coloque na mesma pasta do seu código.

O dataset reúne métricas de todos os jogos da NFL entre 2009 e 2018. Vamos ver qual a cara desses dados.

a) Importe as bibliotecas necessárias e os dados que serão usados

Resposta:

b) Faça um print com as informações gerais do data set: a cara geral dele (head), os nome das colunas, dimensões do dataframe (shape) e o tipo de cada variável.

Resposta:

c) Há erros nos tipos de dados? Responda “sim”, ou “não”. Se houverem, os corrija.

Resposta

d) Quantos dados faltantes ou nulos há no dataset?

Resposta

e) Corrija os dados nulos.

Dica

- Calcule o percentual dos nulos para cada coluna (você pode fazer isso com um loop for):

```
for coluna in colunas:
    total_nulls = coluna.isnull().sum()
    total_cells = len(coluna)
    percentual_nulls = (total_nulls/total_cells) * 100
    print(percentual_nulls)
```

- Para deletar os nulos, use `dropna()`
- Para substituir os nulos, use `fillna()`
- Repare que, se você decidir deletar, todos os dados vão sumir . . .
- Talvez seja melhor substituir eles por Zero.

Resposta:

2) Calcule os parâmetros estatísticos descritivos do seguinte banco de dados. Não se esqueça de colocar as respostas uma após a outra.

Dados disponíveis neste [link](#). Faça download do arquivo `hotel_bookings.csv` e coloque na mesma pasta do seu código.

Baixe os dados e avalie eles a vontade.

...

a) Me mostre uma tabela com as principais variáveis descritivas para todas as colunas: contagem, média, variância, valor mínimo, valor máximo, mediana, e os quartis 25% e 75%.

Dica: é possível fazer isso tudo com apenas uma linha de comando. Resposta

b) Faça um histograma dos campos `is_cancelled`, `lead_time` e `arrival_date_month`

Resposta